UFRN
UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE

Aprendizado Não-Supervisionado

DBSCAN

Prof. Dr. Silvan Ferreira

METRÓPOLE DIGITAL

Clustering

- Assumimos que temos dados $\mathcal{D} = \{x^{(1)}, x^{(2)}, \ldots, x^{(N)}\}, \quad x^{(n)} \in \mathbb{R}^d$
- Cada ponto vive em um espaço Euclidiano: x(n) ∈ R^d
- Supomos que existem K classes (padrões) nos dados
- Hipótese: pontos da mesma classe são próximos
- Pergunta: como identificar essas classes sem conhecer os rótulos?

$$\text{Objetivo: encontrar } \{C_1, \ldots, C_K\} \quad \text{tais que} \quad x^{(i)}, x^{(j)} \in C_k \implies \|x^{(i)} - x^{(j)}\| \text{ é pequeno}$$

Limitações do Clustering Baseado em Distância

- Dificuldade em lidar com clusters irregulares
- Dificuldade em especificar o número de clusters
- Presença de pontos intermediários entre clusters
- Problema com ruídos e outliers
- Precisamos de um algoritmo capaz de:
  - Identificar clusters de forma arbitrária
  - Tratar pontos ruidosos como outliers
  - Não depender do número de clusters pré-definido

Limitações do Clustering Baseado em Distância

k-means

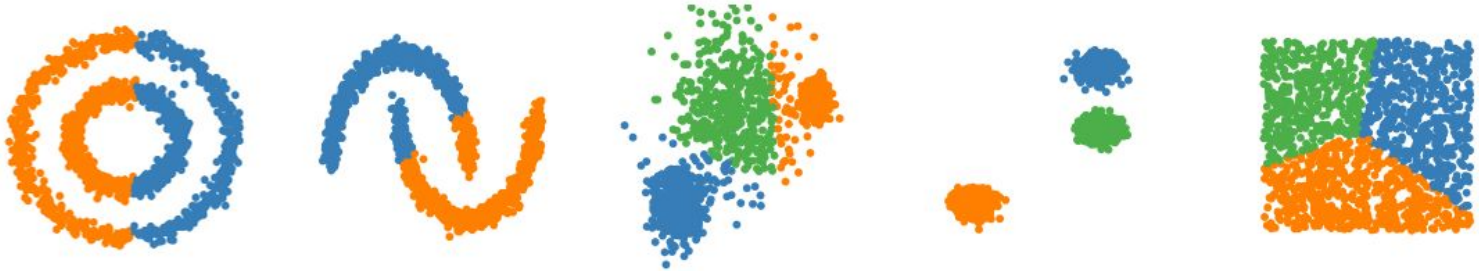

Clusters como Regiões de Densidade

- **Ideia:** cluster = região de alta densidade de pontos
- Clusters se comportam como picos em uma função densidade
- Estimar PDFs em alta dimensão é caro e instável
- DBSCAN evita estimar a densidade explicitamente

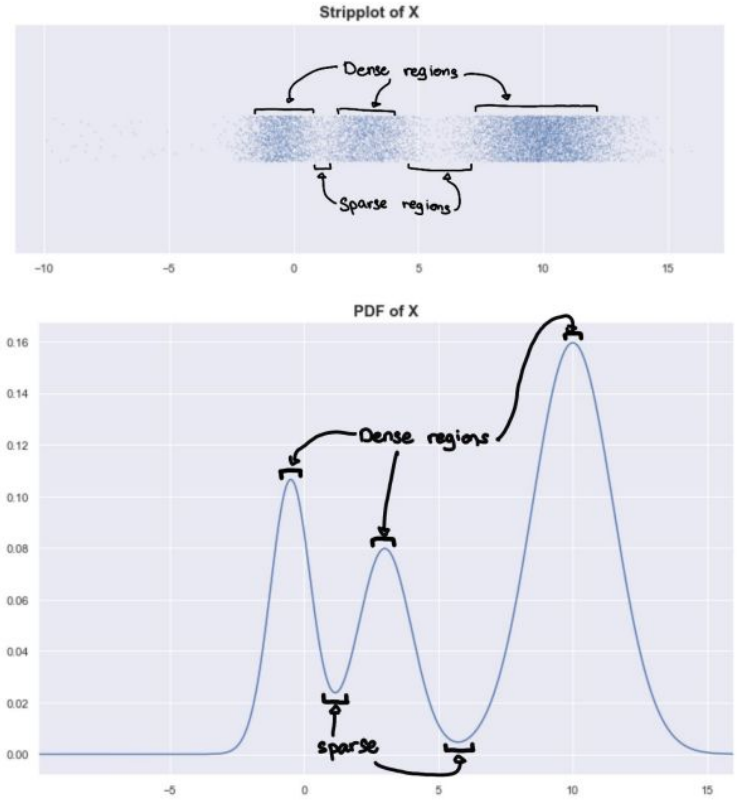

Clusters como Regiões de Densidade

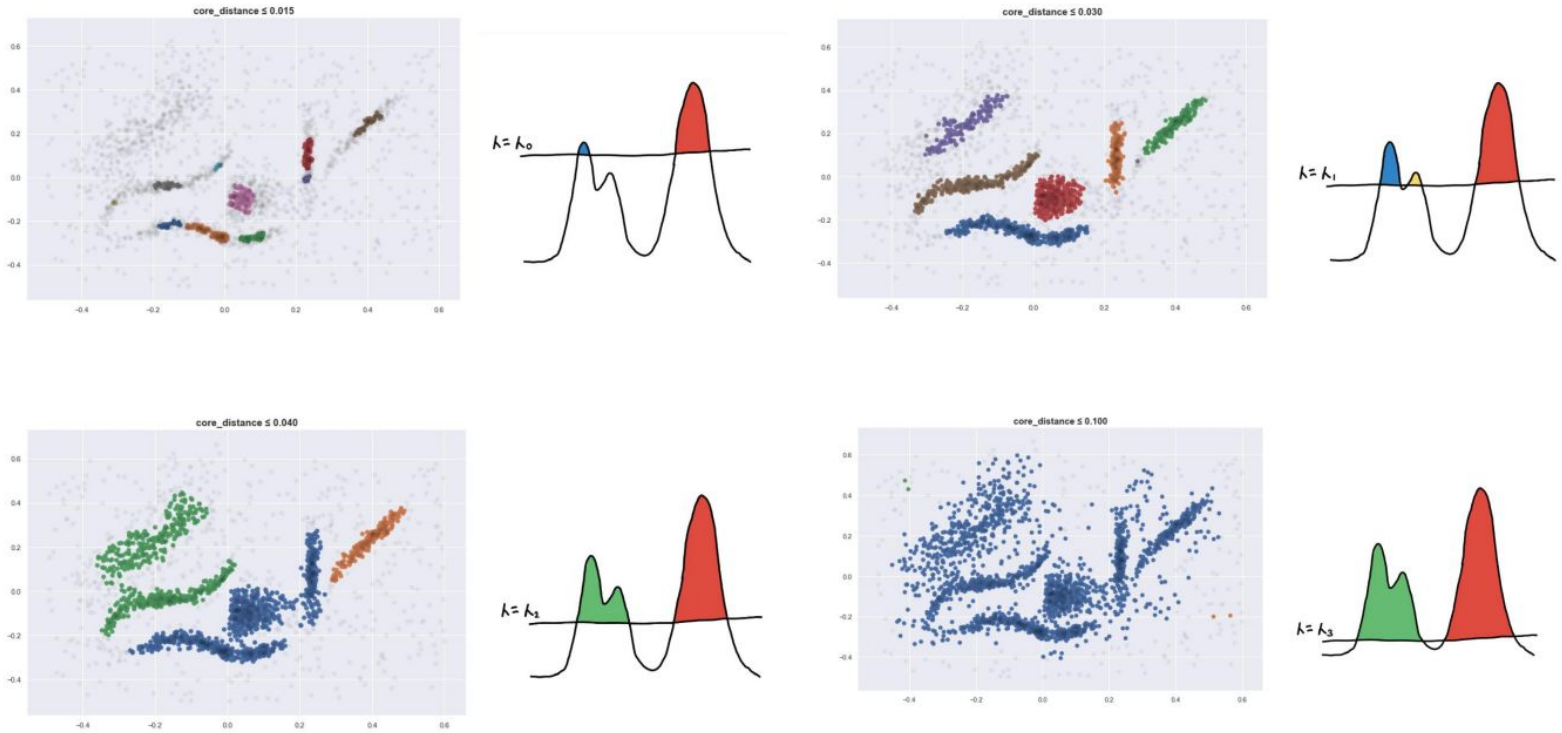

Utilizando a vizinhança

- Contar quantos pontos estão dentro de uma bola de raio ε
- Alta contagem: alta densidade (região candidata a cluster)
- Baixa contagem: baixa densidade (possível ruído)

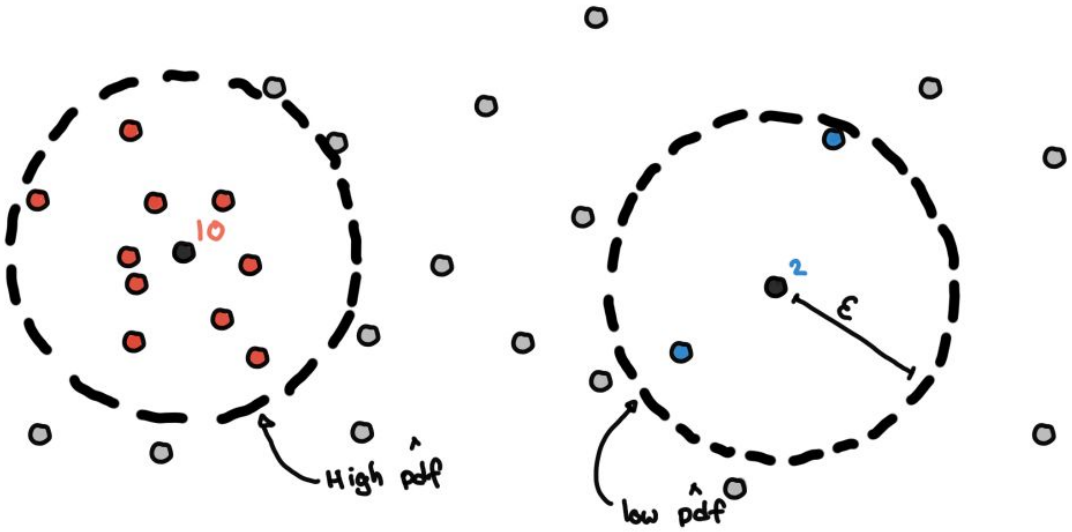

Ideia básica

- **Hipótese central:** clusters = regiões de alta densidade de pontos
- Espaços de baixa densidade separam diferentes clusters
- A densidade é medida a partir de vizinhanças definidas por um raio

DBSCAN

- **Density-Based Spatial Clustering of Applications with Noise**
- A densidade local define quais pontos podem iniciar ou expandir um cluster
- Pontos em regiões pouco densas não se conectam a nenhum cluster
- O algoritmo cresce clusters progressivamente, explorando a vizinhança dos pontos densos
- Resulta em clusters de formas arbitrárias e em pontos classificados como ruído

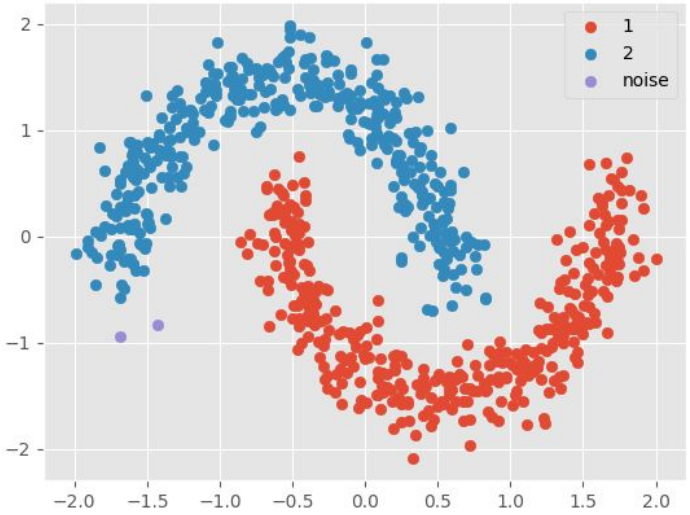

DBSCAN

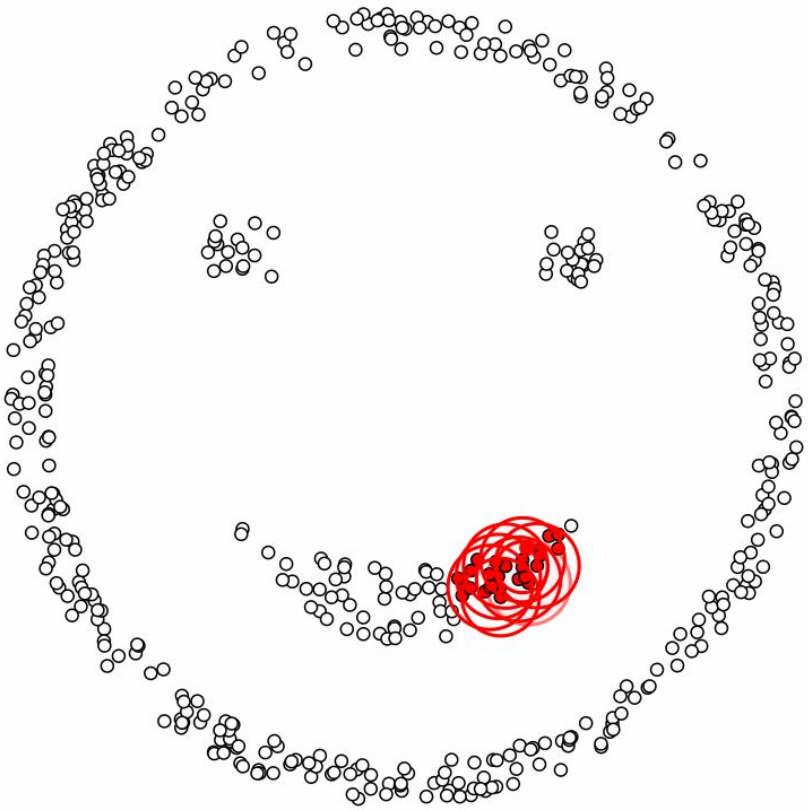

DBSCAN

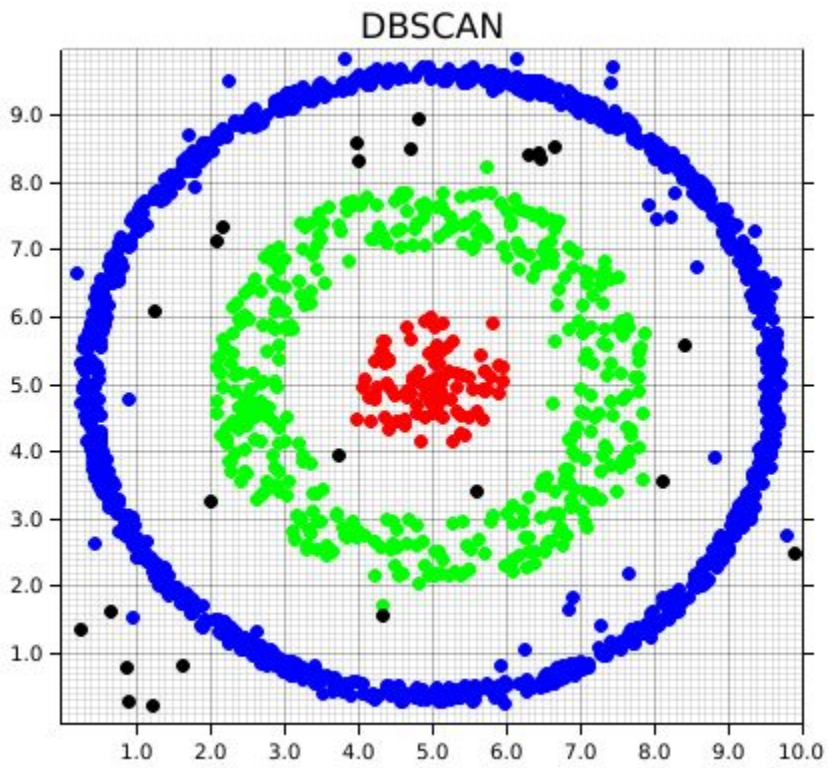
DBSCAN
9.0
8.0
7.0
6.0
5.0
4.0
3.0
2.0
1.0
1.0
2.0
3.0
4.0
5.0
6.0
7.0
8.0
9.0
10.0

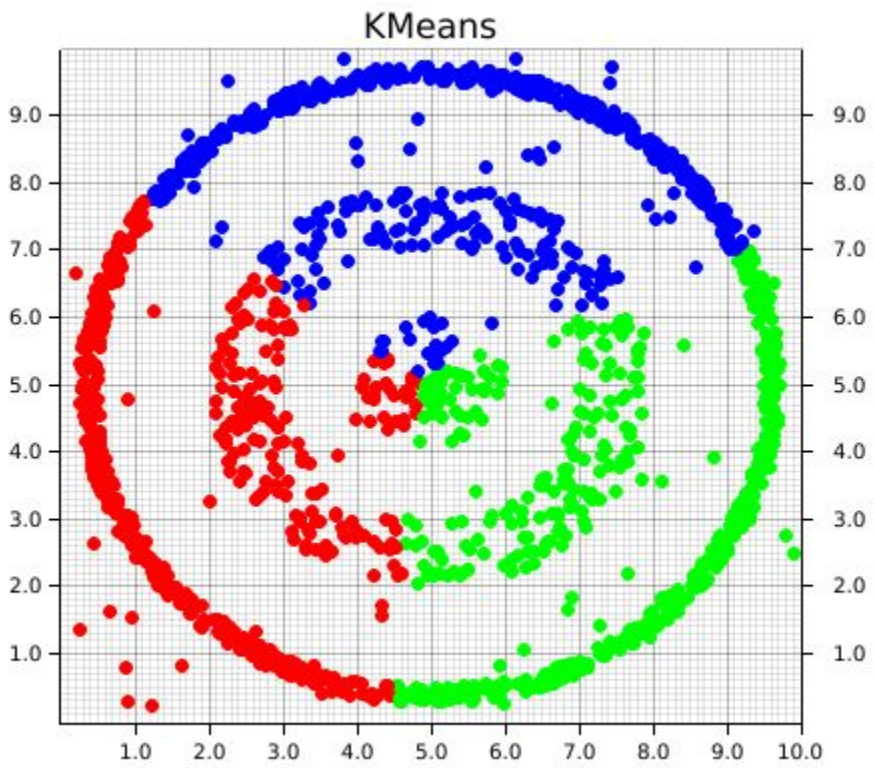
KMeans
9.0
8.0
7.0
6.0
5.0
4.0
3.0
2.0
1.0
1.0
2.0
3.0
4.0
5.0
6.0
7.0
8.0
9.0
10.0

Parâmetros

Dois parâmetros controlam o algoritmo:

- **ε (epsilon):** raio da vizinhança
- **MinPts:** número mínimo de pontos necessários para formar densidade

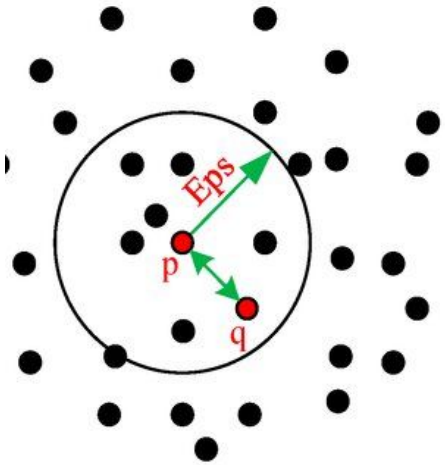

Parâmetros

D : conjunto de dados

p, q : pontos individuais em D

ε : raio da vizinhança (epsilon)

$N_\varepsilon(p)$: conjunto de pontos dentro da vizinhança de p

$|N_\varepsilon(p)|$: número de pontos na vizinhança de p

MinPts : número mínimo de pontos para formar região densa

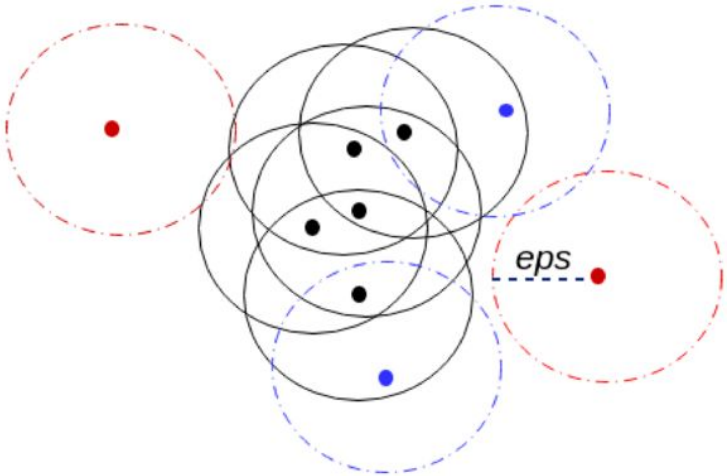

$$N_\varepsilon(p) = \{q \in D \mid \|p - q\| \leq \varepsilon\}$$

$$\text{densidade}(p) = |N_\varepsilon(p)|$$

Tipos de Pontos

Cada ponto é classificado de acordo com sua vizinhança

- **Núcleo:** vizinhança contém pelo menos MinPts pontos
- **Fronteira:** não é núcleo, mas está na vizinhança de um núcleo
- **Ruído:** não é núcleo nem fronteira

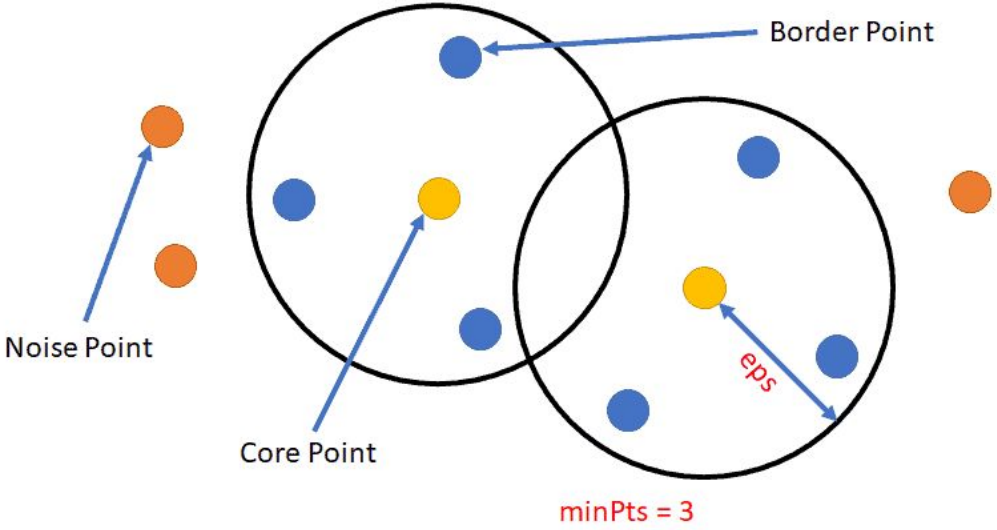

Tipos de Pontos

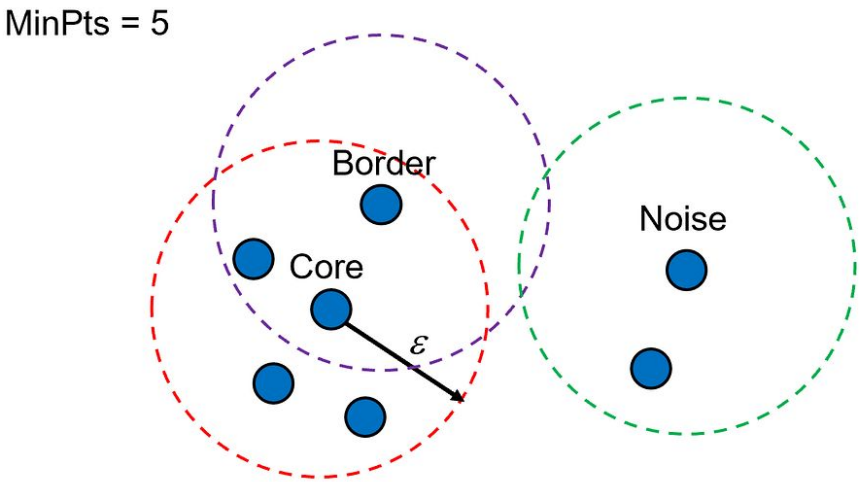

$$\text{Núcleo: } |N_\varepsilon(p)| \geq \text{MinPts}$$

$$\text{Fronteira: } |N_\varepsilon(p)| < \text{MinPts} \quad \wedge \quad \exists q \in D : p \in N_\varepsilon(q),\ q \text{ núcleo}$$

$$\text{Ruído: } |N_\varepsilon(p)| < \text{MinPts} \quad \wedge \quad \nexists q \in D : p \in N_\varepsilon(q),\ q \text{ núcleo}$$

Tipos de Pontos

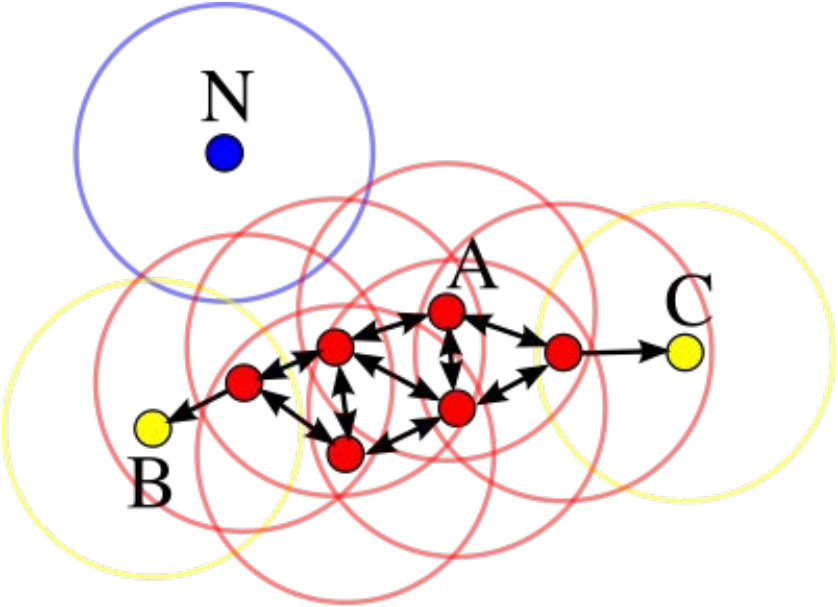

Conectividade de densidade

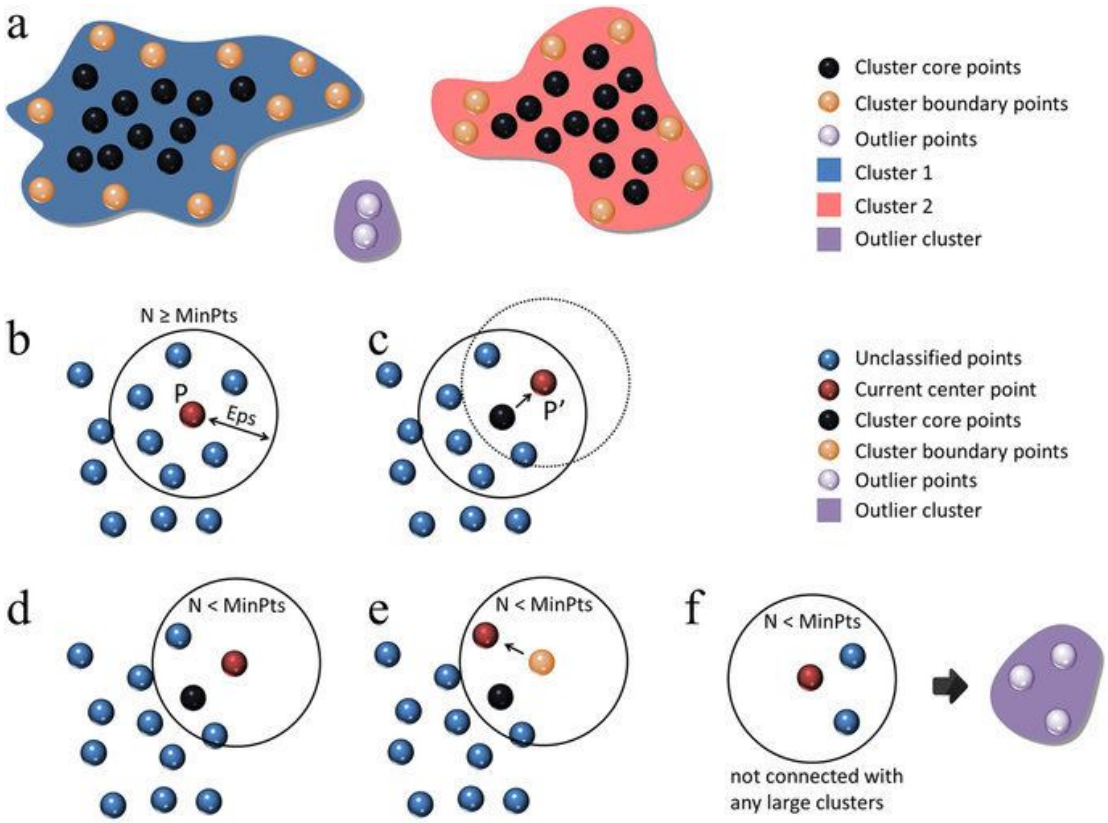

Alcançabilidade da densidade

- Um ponto p é alcançável por densidade a partir de q se:
  - q é um núcleo ($|N_\varepsilon(q)| \geq MinPts$)
  - Existe uma cadeia de pontos $p = p_1, \ldots, p_n = q$
  - Cada p_{i+1} é diretamente alcançável por densidade a partir de p_i
- É possível "caminhar" de q até p passando por pontos núcleo

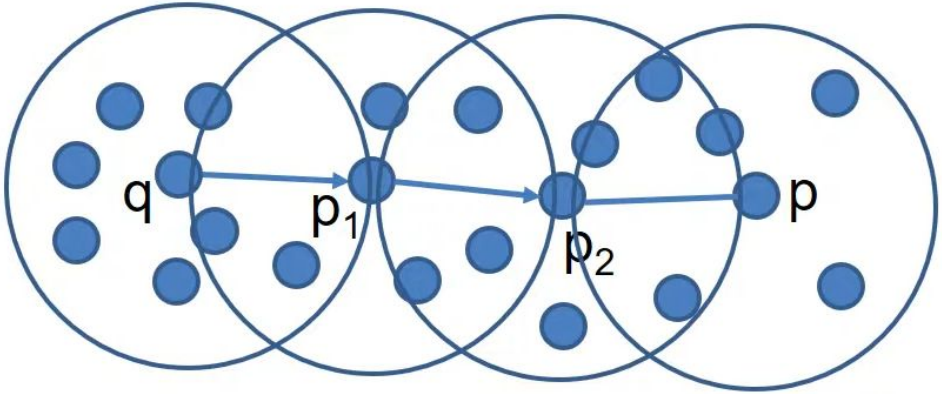

Conectividade de densidade

- Dois pontos **p** e **q** são conectados por densidade se:
  - Existe um ponto **o** tal que
  - **p** é alcançável por densidade a partir de **o**
  - **q** é alcançável por densidade a partir de **o**
- É essa propriedade que define os clusters no DBSCAN

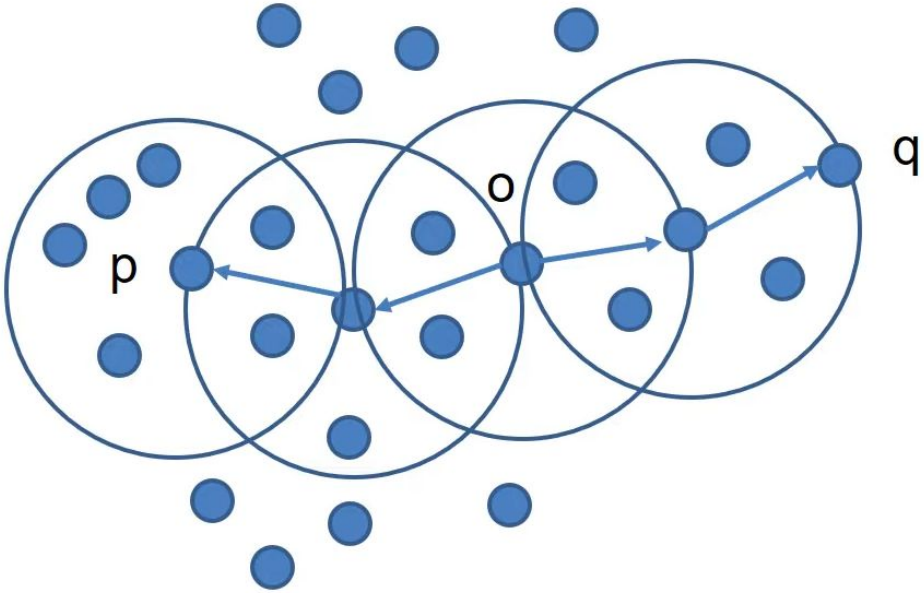

Condição para Clusters

- Dados: conjunto D e parâmetros ε, MinPts
- Um cluster C é um subconjunto de D que satisfaz:
  - **Maximalidade:** Se p ∈ C e q é alcançável por densidade a partir de p, então q também ∈ C
  - **Conectividade:** Para todo p, q ∈ C, p e q são conectados por densidade
- Um cluster contém tanto pontos núcleo quanto pontos de fronteira

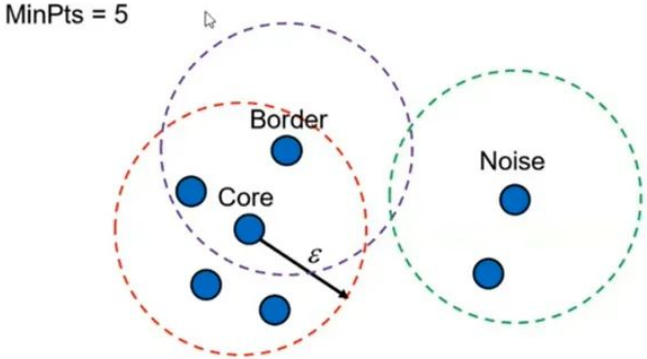

Algoritmo

1. Escolha um ponto ainda não visitado
2. Encontre sua vizinhança ε
3. Se **|Nε(p)| < MinPts** → marque como ruído (pode mudar depois)
4. Se **|Nε(p)| ≥ MinPts** → ponto núcleo, inicia novo cluster
5. Expanda o cluster:
    - Adicione todos os pontos da vizinhança
    - Para cada vizinho núcleo, adicione também sua vizinhança
    - Repita até não haver mais pontos alcançáveis por densidade
6. Continue até visitar todos os pontos

$$\text{Expansão: adicionar todos os } q \in N_\varepsilon(p) \text{ se } |N_\varepsilon(p)| \geq \text{MinPts}$$

Algoritmo

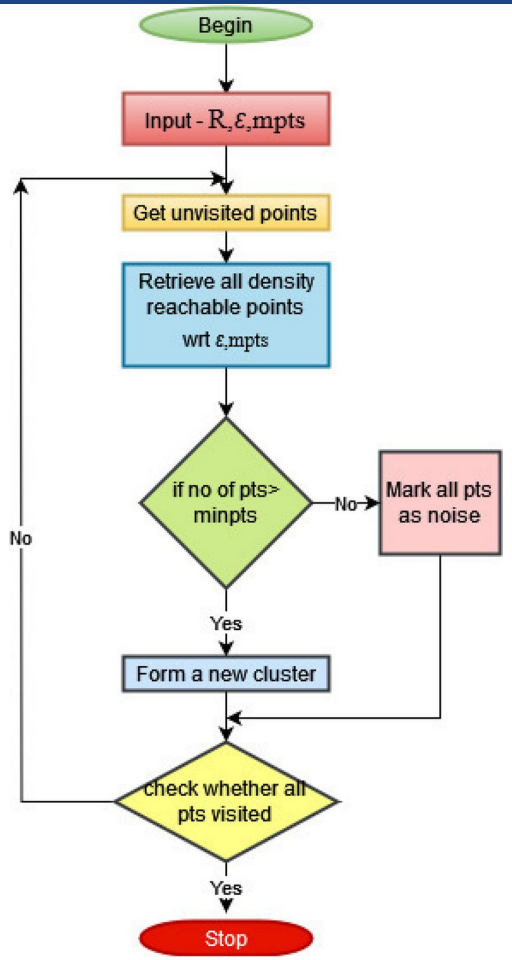
Begin
Input - R,ε,mpts
Get unvisited points
Retrieve all density reachable points wrt ε,mpts
if no of pts> minpts
No
Mark all pts as noise
Yes
Form a new cluster
check whether all pts visited
No
Yes
Stop

Efeito da escolha dos parâmetros

- MinPts baixo → clusters pequenos e frágeis
- MinPts alto → apenas regiões muito densas viram clusters

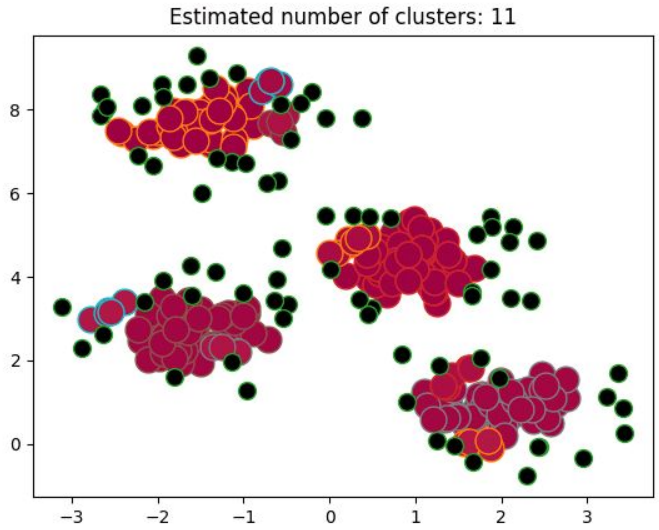

Efeito da escolha dos parâmetros

- ε muito pequeno → muitos pontos marcados como ruído
- ε muito grande → clusters diferentes se fundem

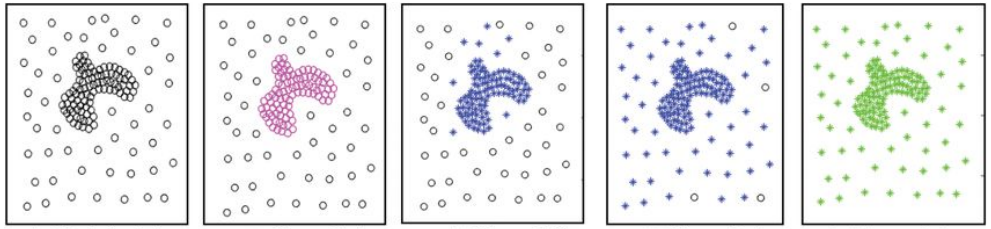

(a) Original dataset **(b)** *Eps* = 1.4 **(c)** *Eps* = 1.8 **(d)** *Eps* = 2.4 **(e)** *Eps* = 2.5

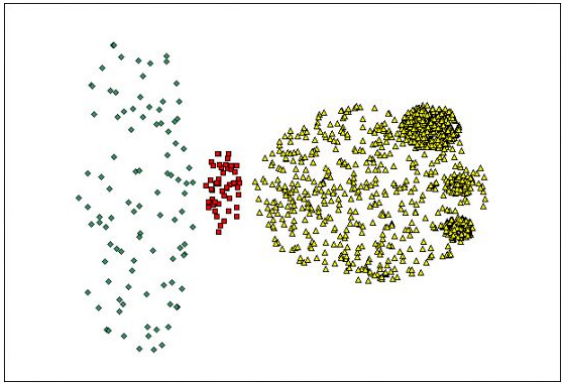

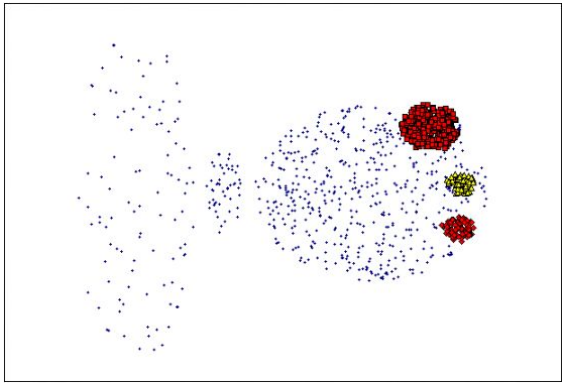

Escolha dos parâmetros do DBSCAN

- **MinPts** define o número mínimo de pontos para formar um núcleo
- Regras práticas para escolha:
  - MinPts de **D+1** até **2D**
  - Valores comuns: entre 4 e 10 em baixa dimensão

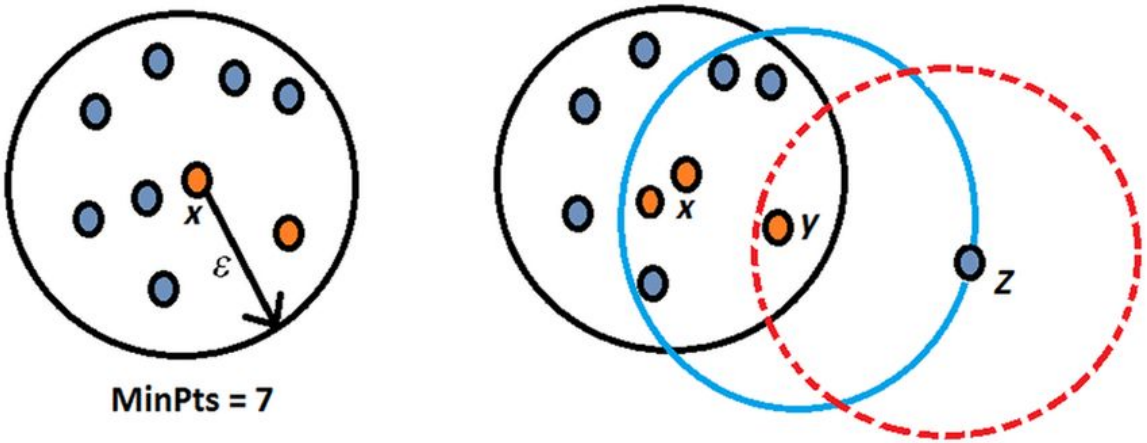

Escolha dos parâmetros do DBSCAN

- Método prático: gráfico **k-distância**
  - Para cada ponto, calcular a distância até seu k-ésimo vizinho mais próximo (k = MinPts)
  - Ordenar essas distâncias em ordem crescente
  - Plotar a curva resultante
- A transição (cotovelo) indica um valor adequado para ε
- Antes do cotovelo → muitos pontos como ruído
- Após o cotovelo → clusters começam a se fundir

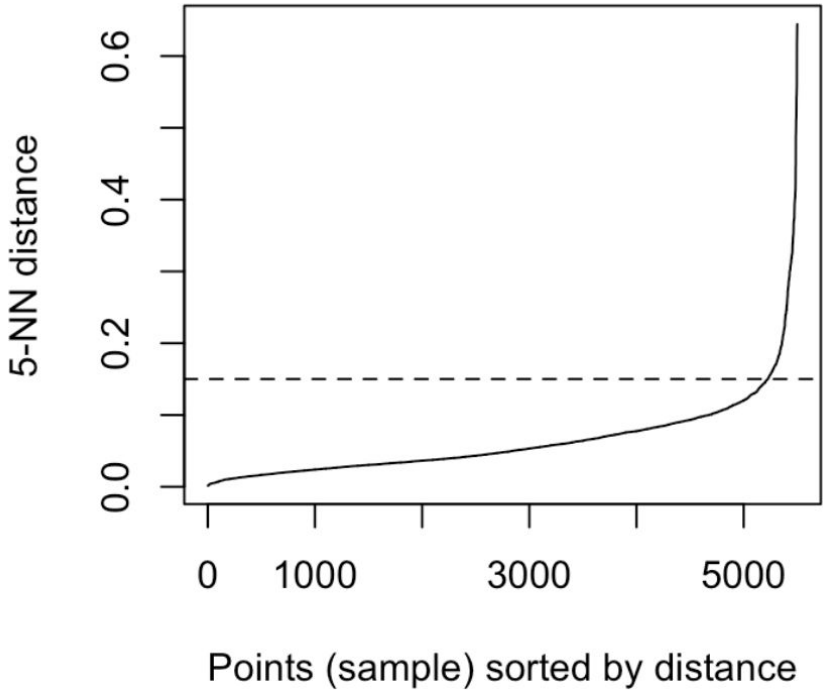

Aplicação: Hotspots Urbanos

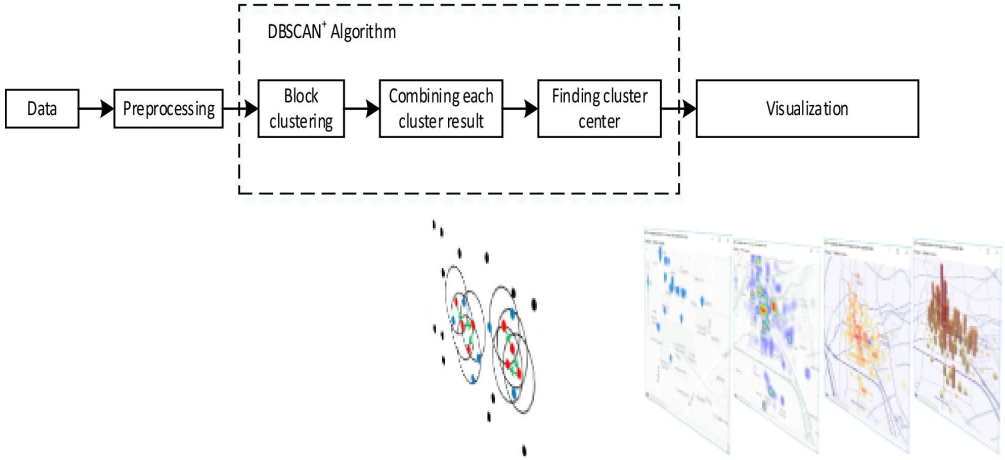

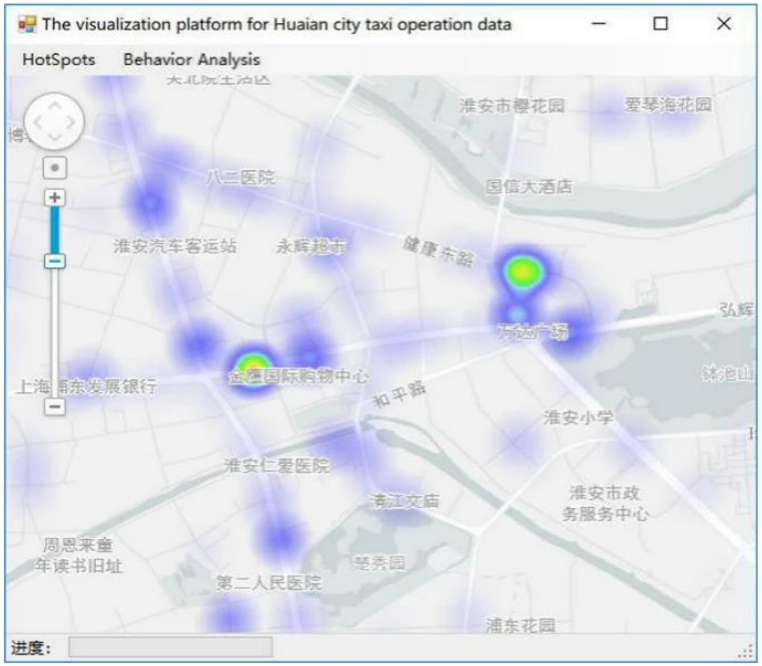

Aplicação: Hotspots Urbanos

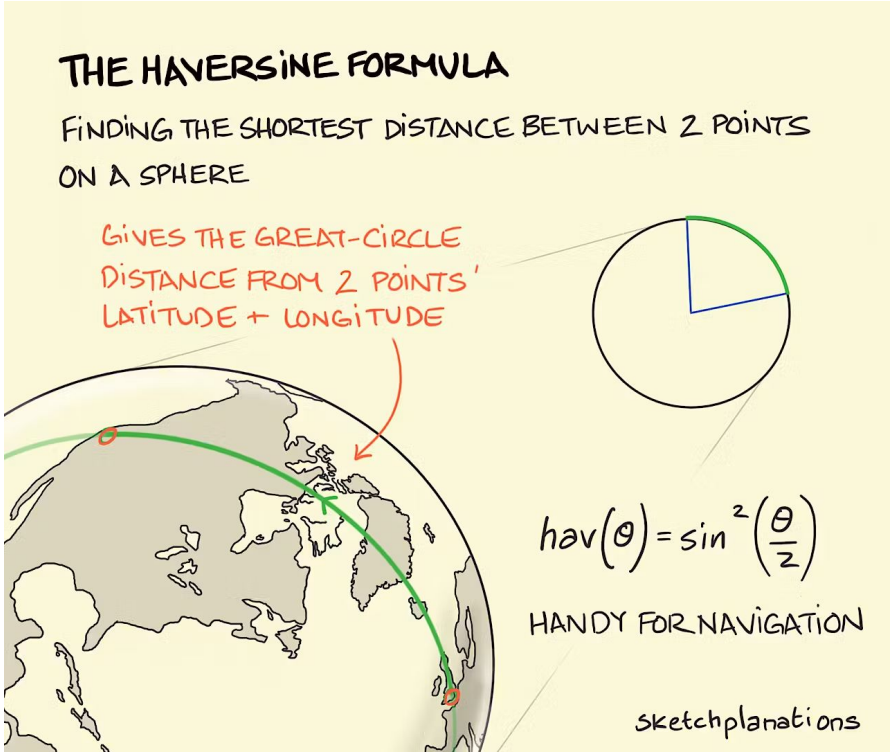

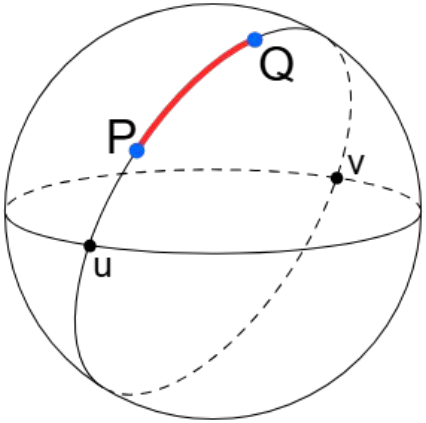

Aplicação: Segmentação de Imagens

Pepper

Segmented Pepper

Mountain

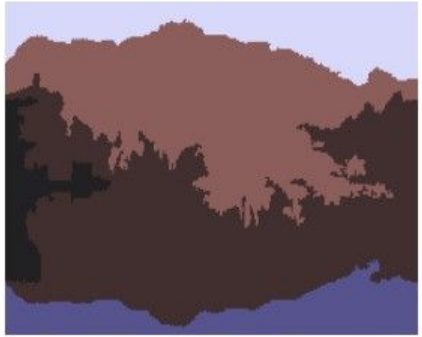

Segmented Mountain

Aplicação: Segmentação de Imagens

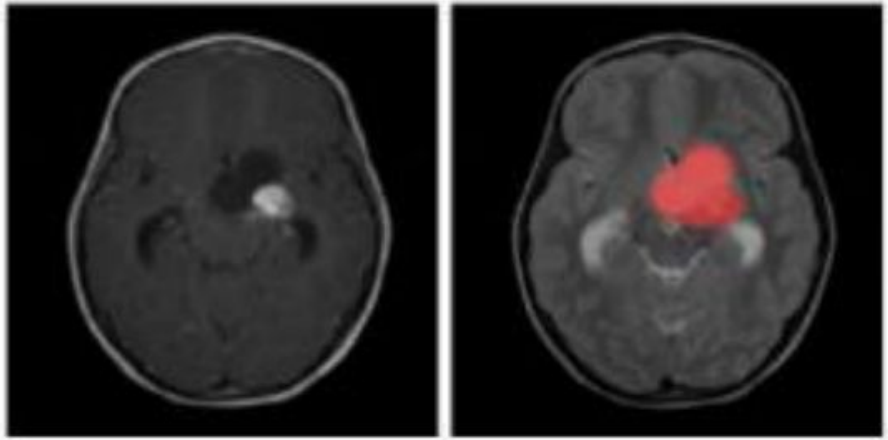

Figure 14. Brain tumor detection using DBSCAN algorithm

Aplicação: Detecção de Anomalias

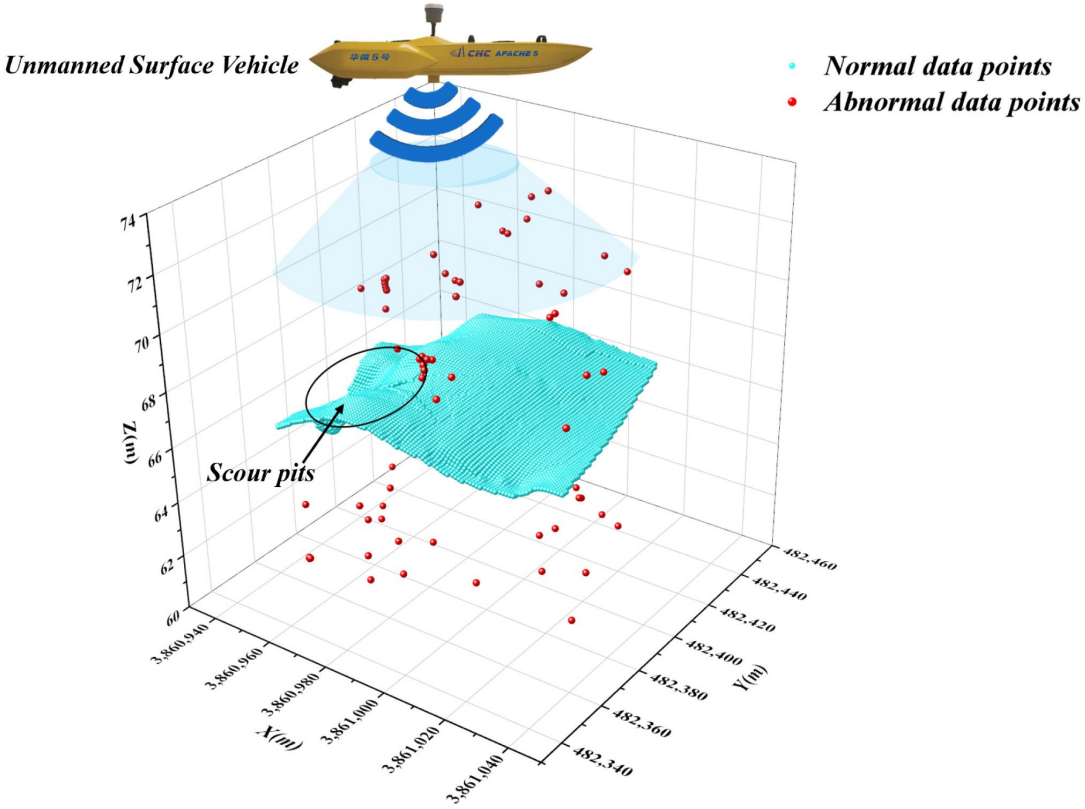

Links Úteis

- https://clustering-visualizer.web.app/dbscan
- https://www.naftaliharris.com/blog/visualizing-dbscan-clustering/

Notebook

- https://colab.research.google.com
- https://github.com/silvaan/unsupervised-learning
- 04 - DBSCAN.ipynb